
Introducción a la simulación

PID_00249438

Pau Fonseca Casas

Tiempo mínimo de dedicación recomendado: 6 horas



Índice

1. Introducción.....	7
2. Objetivos.....	9
3. Conocimientos previos.....	10
4. Qué es la simulación.....	11
5. Ejemplos de sistemas de simulación industrial.....	12
5.1. Simulación de la nueva terminal internacional del aeropuerto de Barcelona	12
5.2. Simulación de la planta de Arbora-Ausonia	14
6. Clasificación de los sistemas de simulación.....	18
6.1. Persona-persona	18
6.2. De sistema	18
6.3. Persona-ordenador	18
6.4. Por ordenador	19
6.5. Tipo Montecarlo	20
6.6. Simulaciones continuas	20
6.7. De eventos discretos	20
7. Periodo de carga frente a periodo estacionario.....	22
8. Generación de números aleatorios.....	23
9. Cuando aplicar simulación.....	24
10. Desventajas de un estudio de simulación.....	25
11. Fases en un estudio de simulación.....	26
11.1. Formulación del problema	28
11.2. Planificación del estudio	28
11.3. Recogida de datos	28
11.4. Implementar el modelo	28
11.5. Validación del modelo de simulación	28
11.6. Ejecuciones de prueba	28
11.7. Validación del modelo	28
11.8. Diseño de los experimentos	29
11.9. Ejecución de los experimentos	29
11.10. Análisis de resultados	29

12. Elementos de un modelo de simulación.....	30
12.1. Entidad	30
12.2. Actividad	31
12.3. Proceso	31
12.4. Recurso	32
13. Estrategias de simulación discreta.....	33
13.1. Programación de eventos (<i>Event Schedulling</i>)	33
13.1.1. Ejemplo de evolución en el tiempo	34
13.1.2. Lista de eventos	35
13.1.3. Motor de simulación	36
13.1.4. Tratamiento de eventos	37
13.2. Interacción de procesos (<i>process Interaction</i>)	38
13.2.1. Ejemplo de evolución en el tiempo	39
13.2.2. Lista de actividades	40
13.2.3. Motor de simulación	40
13.3. Exploración de actividades (<i>activity scanning</i>)	41
13.3.1. Lista de actividades	42
14. Análisis y obtención de datos.....	44
15. El concepto de réplica.....	47
15.1. Intervalo de confianza	48
15.2. Estimación del número «K» de réplicas necesario	49
15.3. Métodos de análisis	49
15.3.1. Repeticiones independientes	49
15.3.2. <i>Batch means</i> (medias de lotes)	50
15.3.3. Métodos regenerativos	50
15.4. Técnicas de reducción de la varianza	50
15.4.1. Números aleatorios comunes	51
15.4.2. Variables antitéticas	51
15.4.3. Variables de control	51
16. Diseño de experimentos en simulación.....	52
16.1. Diseños factoriales	53
16.2. Diseños factoriales 2^k	54
16.2.1. Cálculo de los efectos	55
16.3. Algoritmo de Yates	56
16.4. Determinación de los efectos significativos	58
17. Análisis de resultados en simulación.....	60
17.1. Comparación de dos configuraciones del sistema	60
17.1.1. Comparación de dos configuraciones con igualdad de varianzas	60
17.1.2. Comparación de dos configuraciones con varianzas diferentes	63
17.1.3. Test de igualdad de variancias	64

18. Verificación/Validación y acreditación de un modelo de simulación.....	66
18.1. Verificación	67
18.2. Validación	67
18.2.1. Técnicas informales	68
18.2.2. Técnicas estáticas	68
18.2.3. Técnicas dinámicas	69
18.2.4. Técnicas formales	69
18.3. Acreditación	69
Bibliografía.....	71

1. Introducción

Uno de los principales problemas con los que se encuentran los gestores de muchos de los sistemas reales, como por ejemplo fábricas, aeropuertos u hospitales, es la dificultad que tienen para probar las diferentes alternativas de gestión o de remodelación de sus respectivos sistemas. Obviamente, esto se debe al posible impacto negativo o a su sensibilidad a las modificaciones.

En el marco de la industria 4.0, la simulación constituye un elemento básico para poder determinar el comportamiento de los diferentes subsistemas de una forma local u holística, y presenta una herramienta valiosísima para responder a preguntas del estilo «¿qué pasaría si...?». La simulación permite evaluar alternativas y permite entender el comportamiento del sistema antes de que ninguna de las implementaciones se haga efectiva.

Por tal razón, la simulación es, indiscutiblemente, uno de los pilares centrales de la industria 4.0.

Existen, fundamentalmente, dos grandes categorías en simulación:

- 1) La simulación continua.
- 2) La simulación de eventos discretos.

Durante una simulación de eventos discretos, los cambios ocurren de forma instantánea en puntos aleatorios del tiempo como resultado del tratamiento de los eventos discretos.

Por el contrario, en un sistema continuo, los cambios ocurren continuamente en cualquier instante de tiempo.

Un ejemplo sencillo de sistema de simulación discreto es un sistema de colas, en el que tenemos, como estado del sistema, el número de elementos que tenemos en él. Los eventos que nos provocarían cambios serían la entrada de nuevos elementos en el sistema, y la salida, final de servicio, de los elementos.

Hay que darse cuenta de que entre dos eventos no se producen cambios significativos en el estado del sistema, y que por tanto no es necesario realizar ninguna acción durante estos periodos sin cambio. Esto permite que el sistema implementado en un computador, al final sea más eficiente que si fuese registrando continuamente el estado en el que se encuentra el sistema en cada momento.

Un ejemplo de simulación continua podría ser la cantidad de líquido que hay en un recipiente que se está vaciando. Su estado, definido por su variable de estado, cantidad de líquido, varía continuamente a lo largo del tiempo que dura el estudio.

Este sistema de simulación suele requerir ecuaciones diferenciales para poder ser descrito, lo que implica que el análisis suele ser complejo. Sin embargo, muchas veces se puede aproximar el comportamiento continuo de un sistema a partir de un modelado basado en eventos discretos. Esto simplifica notablemente la dificultad del análisis.

Sobre la base de los conocimientos adquiridos hemos de ser capaces de plantear preguntas a los modelos de simulación contruidos y, más importante, aprenderemos a usar un conjunto de técnicas para proporcionar las respuestas de la simulación de modelos con el rigor necesario para que puedan ser aceptados.

2. Objetivos

Introducir al alumno en el mundo de la simulación computacional:

1. Introducir al alumno en conceptos de simulación discreta.
2. Definir las diferentes fases que existen en un proyecto de simulación.
3. Ser capaz de determinar y definir los diferentes elementos que existen en un modelo de simulación.
4. Introducir al estudiante a los fundamentos de la metodología de pruebas de simulación discreta.
5. Construir un diseño experimental para un problema dado.

3. Conocimientos previos

Se requieren conocimientos básicos de estadística descriptiva.

Es necesario que el alumno tenga capacidad para generar sus propias funciones de distribución y generadores de números aleatorios.

Asimismo, es muy interesante que conozca un lenguaje de programación orientado a objetos para poder implementar sin dificultades los algoritmos que se mostrarán.

4. Qué es la simulación

Podemos empezar con una definición:

«La simulación es el proceso de diseñar un modelo de un sistema real y de desarrollar experiencias con él con la finalidad de comprender el comportamiento del sistema o evaluar nuevas estrategias para el funcionamiento del sistema, dentro de los límites impuestos por cierto criterio o por un conjunto de ellos». R. E. Shannon

Tradicionalmente, el modelado mediante ecuaciones diferenciales ha sido uno de los métodos más comúnmente utilizados para el estudio de diferentes sistemas. Con el continuo refinamiento de los modelos y con la necesidad de llegar cada vez más lejos en la comprensión y la predicción del comportamiento los sistemas, los modelos matemáticos resultantes cada vez eran más complejos, cosa que dificulta el trabajo en un doble sentido. Primero por la dificultad creciente para modelar los sistemas con más y más detalle; segundo, para que, una vez que se ha conseguido el modelado, se pueda generar o calcular una solución del modelo.

Con la aparición de las computadoras, se multiplicó la potencia de cálculo de los investigadores, y los modelos que podían construir eran cada vez más detallados y precisos, al tiempo que permitían una mayor recogida de información de estos, lo que evidentemente aumentaba su utilidad.

Bibliografía recomendada

Algunas referencias bibliográficas que nos pueden ser útiles para empezar a entender el mundo de la simulación son:

Banks, J. (ed.) (1998). *Handbook of Simulation Principles, Methodology, Advances, Applications, and Practice*. Nueva York: John Wiley & Sons.

Fonseca i Casas, P. (2009). *Simulació discreta per mitjà de la interacció de processos*. Barcelona: Edicions UPC.

Fonseca i Casas, P. (2014a). *Formal languages for computer simulation: Transdisciplinary models and applications*. Hershey, PA: IGI Global. DOI:10.4018/978-1-4666-4369-7

Kelton, W. D.; Sadowski, R. P.; Sturrock, D. T. (2010). *Simulation with Arena*. Nueva York: McGraw-Hill.

Law, A. M.; Kelton, W. D. (2000). *Simulation modeling and analysis* (3.^a ed.). Nueva York: McGraw-Hill.

Robinson, S. (2003). *Simulation: The Practice of Model Development and Use*. Nueva York: John Wiley & Sons.

Wainer, G. A.; Mosterman, P. J. (2009). *Discrete-Event Modeling and Simulation: Theory and Applications*. Boca Raton, FL: CRC Press.

5. Ejemplos de sistemas de simulación industrial


Un ejemplo interesante es el modelado de sistemas aeroportuarios. En este sentido, vamos a presentar algunos detalles de un trabajo que tenía como objetivo el modelado del aeropuerto internacional de Barcelona. El trabajo completo se puede consultar en Fonseca, Casanovas y Ferran (2014).

5.1. Simulación de la nueva terminal internacional del aeropuerto de Barcelona

Este ejemplo, dada la magnitud del problema, plantea la necesidad del uso de sistemas formales para definir el comportamiento del modelo. Estas técnicas se explicarán más adelante en el segundo módulo de simulación. Concretamente en este proyecto se usó el lenguaje SDL (Specification and Description Language), para definir el comportamiento de los diferentes elementos que constituían el aeropuerto.

Como ejemplo de la estructura del modelo y del lenguaje, en la figura 1 se puede ver un esquema simplificado del modelo usado. En este punto simplemente hay que notar que este primer diagrama permite que entendamos los elementos básicos constitutivos del modelo y, por tanto, todo aquello que no formará parte del estudio de simulación. En Fonseca (2011) se presenta una taxonomía para trabajar con hipótesis de simulación.

Figura 1. Diagrama de sistema SDL para el modelo del aeropuerto.




Fuente: Fonseca, Casanovas y Ferran (2014).

A partir de definir el modelo, podemos pasar a tratar los diferentes elementos constitutivos de él. En este caso, fundamentalmente, la plataforma, la terminal y los accesos.

En este caso, la construcción del modelo permitió la representación completa del comportamiento de los pasajeros, a partir de su definición como agentes inteligentes. Esto permitió determinar los espacios, flujos y operaciones permitidas para dar un nivel de satisfacción adecuado a los pasajeros.

Figura 2. detalle del embarque i desembarque.




Fuente: Fonseca, Casanovas y Ferran (2014).

A partir de este modelo, los gestores del aeropuerto tenían una herramienta para, en tiempo real, analizar el comportamiento del aeropuerto, detectar posibles anomalías y proponer alternativas. El sistema, que se pretendía integrar con el SATE, a partir de sensores, permitía la optimización y la gestión en tiempo real de él.

La simulación completa del sistema, ver figura 3, permitió a los gestores determinar los espacios y los flujos de la sección principal del aeropuerto.

Figura 3. Sección del NAT.



Fuente: Fonseca, Casanovas y Ferran (2014).

En este ejemplo, el modelo permitió determinar los espacios del sistema por construir y, una vez construido. Luego, a partir de su conexión con sensores, dejó monitorizar y optimizar en tiempo real la operativa del sistema. A continuación, vamos a presentar otro ejemplo en el que se persiguió la representación formal no únicamente de los elementos del sistema, sino también de su representación.

5.2. Simulación de la planta de Arbora-Ausonia

En este ejemplo vamos a destacar la posibilidad de un lenguaje formal, como SDL, de comunicarse con sistemas externos de forma fácil y de representar en formato de realidad virtual o aumentada el sistema que especifica. El ejemplo que presentamos está basado en el artículo de Fonseca, Pi, Casanovas y Jové (2013).


El problema que se plantea resolver es el de definir un equivalente virtual a un sistema que se plantea construir en una fábrica de Arbora-Ausonia. Para ello, se planteó especificar no únicamente el comportamiento del sistema, sino también el comportamiento que los elementos de representación debían tener.

Esto tenía como objetivo permitir que la especificación fuera completa, en el sentido de que no únicamente representaba estructura y comportamiento, sino también la interfaz de comunicación y de representación del modelo.

La especificación del modelo se realizó con SDL; tal como se puede ver en la figura 4, contaba principalmente con cuatro elementos fundamentales que se querían representar: un punto de entrada de elementos, la cinta, el robot que procesaba los elementos y el elevador. Como se verá más adelante, cada elemento SDL que tenemos representado en este diagrama es un AGENTE.

La representación de los diagramas SDL permite incluir elementos de información; en este caso, se optó en que cada AGENTE SDL (los elementos que hemos comentado) incluyeran información referente a su representación.

Figura 4. Diagrama de sistema para el modelo de Arbora-Ausonia.



Esta información de representación se añadía a partir de mapear la posición que ocupaba el objeto en la especificación, dotando de una información de tipo posicional a cada elemento. En la figura 5 se puede ver la información posicional para el AGENTE BRobot.

Figura 5. Información posicional para el objeto robot.

```


<ModelInfo>
  <ModelName>Ausonia</ModelName>
  <Agents>
    <Agent name='BRobot_PRobot'>
      <state name='IDLE'>
        <mesh scale='1'>box_green.obj</mesh>
        <pos x='420' y='0' z='0' />
        <rot x='0' y='0' z='0' />
      </state>
      <state name='BLOCKED'>
        <mesh scale='1'>box_red.obj</mesh>
        <pos x='420' y='0' z='0' />
        <rot x='0' y='0' z='0' />
      </state>
      <state name='WORKING'>
        <mesh scale='1'>box_yellow.obj</mesh>
        <pos x='420' y='0' z='0' />
        <rot x='0' y='0' z='0' />
      </state>
    </Agent>
  </Agents>
</ModelInfo>

```

Esta información de tipo posicional se completa con una información que ha de permitir representar el objeto en un espacio tridimensional con una forma concreta. Esto está recogido en el campo *mesh*. A partir de esta descripción, cada AGENTE SDL contaba con una posición, que podía modificarse en función del comportamiento del modelo; además, contaba con una representación para cada uno de los diferentes estados del modelo. Esto permite que el objeto se representará diferente si, por ejemplo, está en el estado *working* o en el estado libre *idle*.


A partir de esta definición formal del modelo, que incluía los elementos de representación, fue posible obtener una representación como la que se presenta en la figura 6.

Figura 6. Representación del AGENTE cinta.



Esta representación, estaba conectada con el comportamiento del modelo a partir de la instrucción *AnimTo* (ver figura 7), que permitía especificar el movimiento de los AGENTES a su nueva posición.

Figura 7. Instrucción AnimTo para conectar el comportamiento del modelo con su representación.



En este ejemplo hemos mostrado, simplemente, cómo se puede usar un lenguaje formal como SDL (que veremos más adelante) para crear un sistema comúnmente denominado *DigitalTwins*, que es una réplica de un sistema real, exista o no; además, se puede establecer un mecanismo de comunicación entre ellos. La flexibilidad de estos sistemas es clave para poder modificar el modelo a partir de las lógicas evoluciones del sistema.

6. Clasificación de los sistemas de simulación

Los principales tipos de simulaciones que nos podemos encontrar son los siguientes, en función de los elementos que están involucrados:


6.1. Persona-persona

Simulaciones de tipo social donde estudian reacciones de personas o de colectivos. Por ejemplo: entrenamiento para entrevistas de trabajo.

6.2. De sistema

Simulaciones donde se reproduce físicamente un sistema físico, químico, biológico, etc., bajo unas condiciones controladas. Un ejemplo muy interesante es el modelo de sistema que Antoni Gaudí desarrolló para poder calcular los ángulos en las columnas de la cripta de la Sagrada Familia (ver figura 8).

Figura 8. Modelado de sistema de la cripta de la Sagrada Familia.



6.3. Persona-ordenador

Simulaciones donde la persona responde a unas cuestiones planteadas por el ordenador. Por ejemplo: entrenamiento mediante juegos de estrategia financiera; simuladores de vuelo, etc.


Figura 9. Simulador de entrenamiento para el Airbus 380.



6.4. Por ordenador

No requieren de interacción. A partir de una entrada, un programa la transforma obteniendo una salida. Normalmente responden a sistemas estocásticos.

Figura 10. Simulación de dos galaxias interactuando.



Fuente: By SiriusB [GFDL (<http://www.gnu.org/copyleft/fdl.html>) or CC-BY-SA-3.0 (<http://creativecommons.org/licenses/by-sa/3.0/>)], via Wikimedia Commons.

Otra clasificación que podríamos establecer estaría basada en la técnica de simulación que emplearemos, así tendríamos:

6.5. Tipo Montecarlo

No interviene el tiempo y se basan en la aleatoriedad y la probabilidad. Por ejemplo: cálculo de juegos de solitario realizables.

6.6. Simulaciones continuas

Sistemas modelados por ecuaciones diferenciales o algebraicas que dependen del paso del tiempo de forma continua.

Ejemplo

Sistemas Tom y Jerry (o depredador-presa).

6.7. De eventos discretos

Se caracterizan por el paso de bloques de tiempo «en los que no pasa nada» y donde puntúan acontecimientos que cambian el estado del sistema. Se basan en teoría de colas.

Ejemplo

Estudio de un peaje o de un cajero automático.

Teniendo en cuenta las tres grandes técnicas de simulación mencionadas anteriormente, podríamos clasificar los sistemas de la siguiente forma.

En función de su evolución temporal:

- **Estáticos:** dan representación del sistema en un momento dado, no interviene el tiempo, la técnica de Montecarlo sería adecuada para un estudio de este estilo.
- **Dinámicos:** representan la evolución de las variables de estado a lo largo del tiempo.

En función del tipo de variables que intervienen, podemos establecer la siguiente clasificación:

- **Deterministas:** no interviene el azar en ninguna variable del sistema.
- **Tocásticos:** interviene el azar o elementos que no controlamos.

Ved también

Para obtener una recopilación histórica de estos métodos se puede consultar la web: <http://landau.mines.edu/~jscales/inverse/node154.html>

Finalmente, también podríamos establecer una clasificación en función de la evolución de las variables de estado:

- **Discretos:** las variables de estado varían únicamente en determinados instantes de tiempo.
- **Continuos:** las variables de estado varían continuamente a lo largo del tiempo.

7. Periodo de carga frente a periodo estacionario

En todo modelo suele haber dos fases claramente diferenciadas que definen el comportamiento global del sistema.

Estas dos fases son el periodo de carga (o transitorio) y el estado estacionario.

El estado estacionario es aquel en el que el sistema se extiende a lo largo del tiempo; normalmente se estudia en las soluciones analíticas más comunes, como, por ejemplo, en teoría de colas.

El periodo de carga (o transitorio) es aquel espacio de tiempo en el que el sistema aún no ha llegado al estado estacionario, y en el que oscila entre diferentes valores, sin todavía una definición clara.

Tradicionalmente, el periodo estacionario ha sido siempre el que ha despertado más interés de cara al estudio de los sistemas; sin embargo, con un modelo de simulación es posible estudiar los dos periodos de forma casi idéntica.

8. Generación de números aleatorios

Para poder generar números aleatorios reales, existen una serie de dispositivos físicos que, normalmente conectados al puerto serie del PC, introducen ruido completamente aleatorio.

Normalmente, sin embargo, los requerimientos de la experimentación no necesitan números aleatorios reales; deja trabajar con números pseudo-aleatorios o, lo que es lo mismo, con números que tienen apariencia de aleatorios, pero que en realidad no lo son.

La generación de números pseudo-aleatorios es algo primordial dentro del mundo de la simulación, pues permite dotar a los modelos de una sensación de aleatoriedad necesaria para poder extrapolar los resultados obtenidos al sistema estudiado.

Sin una buena generación de números pseudo-aleatorios, no existiría dentro del modelo ningún mecanismo para poder generar las diferentes distribuciones de probabilidad que rigen el comportamiento de los diferentes elementos del sistema; por tanto, sería imposible realizar la simulación.

9. Cuando aplicar simulación

La simulación no se aplicará para resolver cualquier problema, sino que lo primero que debe evaluar es si existen otras herramientas o recursos para poder afrontar el problema con garantías de éxito, y con unos costes computacionales y de tiempo menores.

En principio, las normas que nos dicen cuando es interesante aplicar simulación se pueden resumir en los siguientes puntos:

- O existe una formulación completa del problema, o no hay métodos analíticos para poder resolverlo.
- Son necesarias unas hipótesis simplificadoras para resolver los métodos analíticos planteados, que desvirtúan completamente las soluciones obtenidas y su interpretación.
- Los métodos analíticos son muy difíciles de llevar a cabo, a pesar de que existen, y no requieren de hipótesis simplificadoras.
- Queremos observar la historia de la evolución del modelo, y no solo el resultado de su comportamiento en el estado estacionario, o queremos estudiar el periodo de carga o transitorio del sistema.
- Queremos tener un sistema que no solo nos proporcione respuestas, sino también que nos permita modificar dinámicamente algunos de los factores que determinan el comportamiento del modelo.

10. Desventajas de un estudio de simulación

La simulación presenta los siguientes inconvenientes, que hay que tener presentes para que cualquier proyecto de simulación pueda salir adelante.


- Es costoso en horas de desarrollo.
- Hay que destinar un tiempo a la verificación del programa construido.
- Asimismo, habrá un tiempo para poder validar los resultados del modelo, y calibrarlo.
- Para obtener respuestas es necesario gastar horas de computadora.
- Es preciso disponer de personal con conocimientos estadísticos para poder recoger e interpretar la información.
- Hay que conocer y explicar con detalle el modelo, no es factible el esquema de una caja negra, para que las personas que al final tienen que tomar las decisiones confíen en el modelo.

Estos inconvenientes suelen estar relacionados con la falta de tiempo que hay para los proyectos de simulación, debido a que sus respuestas son fundamentales para sacar adelante un determinado proyecto con una configuración u otra; por eso hay que tenerlos muy en cuenta cuando se pide un estudio sobre un determinado sistema.

11. Fases en un estudio de simulación

Todo estudio de simulación ha de intentar definir un modelo a partir de un sistema acotado a partir de las hipótesis por usar. Esquemáticamente, lo que se persigue es un desarrollo en bucle que puede verse esquemáticamente en la figura 11.


Figura 11. Ciclo de desarrollo simplificado de un modelo de simulación.



La definición de las hipótesis que quedan dentro o fuera de un estudio de simulación son una pieza clave. Se puede encontrar más información al respecto en Fonseca (2011).

De forma más lineal, las diferentes fases que existen en un estudio de simulación se pueden observar en la figura siguiente:

Figura 12



Cada una de estas fases representan las siguientes tareas:

11.1. Formulación del problema

En esta fase se define el problema o problemas que se pretenden estudiar. Incluye sus objetivos.

11.2. Planificación del estudio

Una vez que ya se tienen claros los problemas que hay que analizar y los objetivos que se desean obtener, se ha de planificar el proyecto de simulación.

11.3. Recogida de datos

Hay que identificar, recoger y analizar los datos necesarios para desarrollar el estudio de simulación.

11.4. Implementar el modelo

A partir de los datos obtenidos, su naturaleza y su estructura, es necesario desarrollar un modelo de simulación que permita obtener los resultados que se desean.

11.5. Validación del modelo de simulación

Hay que comprobar que, efectivamente, el modelo de simulación que se ha construido, el programa, responde adecuadamente a sus expectativas de funcionamiento. Esta fase correspondería a la verificación de que el algoritmo empleado funcione de forma correcta.

11.6. Ejecuciones de prueba

Una vez que el algoritmo ya está suficientemente probado, hay que empezar la fase de validación, en la que se comprobará no solo el funcionamiento correcto del programa, sino también la naturaleza correcta de los datos resultantes de este. Por eso hay que construir un conjunto de ejecuciones de prueba que permitan realizar esta validación. Normalmente, estos conjuntos de ejecuciones se basan en datos históricos, que permiten comparar los datos del modelo, con los datos que deberían salir del modelo (datos históricos) o en modelos sencillos que, a partir del análisis realizado por un experto en el sistema, permita evaluar la corrección del modelo.

11.7. Validación del modelo

A partir de los modelos de prueba, se comprueban los datos resultantes con los datos esperados. Normalmente, en esta fase se requiere de la ayuda de personas expertas en el sistema modelado.

11.8. Diseño de los experimentos

Una vez que los datos que se obtienen del modelo de simulación ya se dan por válidas, hay que diseñar los experimentos que permitirán obtener los resultados deseados a las preguntas planteadas inicialmente, en la *Formulación del problema*.

11.9. Ejecución de los experimentos

Los experimentos de simulación pueden ser largos de realizar, por eso hay que tener en cuenta una fase en la que se realizan. Hay que tener en cuenta que un diseño experimental correcto debe contar con un número n de repeticiones (réplicas); por lo tanto, la duración de los experimentos de simulación puede que no se conozca a priori.

11.10. Análisis de resultados

Una vez que ya se tienen los resultados de los experimentos, se deben analizar. En este punto, hay que plantear nuevos experimentos si es necesario.

12. Elementos de un modelo de simulación

Dentro de todo modelo de simulación, siempre existen una serie de elementos comunes que permiten construirlo. Hacen que sea lo más parecido a la realidad del sistema.

Estos elementos varían significativamente su comportamiento de un modelo a otro, pero normalmente siempre se debe a la parametrización que reciben en cada caso.

Los elementos más importantes son:

- Entidad
- Actividad
- Proceso
- Recursos

12.1. Entidad

Una entidad es un elemento del sistema que normalmente fluye por él y que tiene una vida finita dentro del modelo. Otra característica importante es que muchas veces las entidades representan los elementos que reciben las transformaciones u operaciones que se dan dentro del modelo.

Ejemplos

Entidades serían las botellas que se etiquetan en un modelo que representa un sistema de etiquetado de botellas.

También podrían ser las cajas en un almacén de una fábrica, en la que el modelo quiere analizar el movimiento de estas a través de las diferentes estructuras del sistema.

En cualquier caso, las entidades, normalmente presentan una serie de características que permiten establecer un conjunto de criterios para poder decidir qué elemento es susceptible de ser o no ser una entidad.

Una primera característica sería que toda entidad puede tener una vida finita dentro del modelo de simulación. Es decir, toda entidad tendrá un momento de creación y, normalmente, un instante de destrucción. Aquellas entidades

que no se destruyen dentro del modelo suelen ser entidades de control, que permiten entender con más facilidad la estructura del modelo. Estas entidades de control también se llaman máquinas o entidades permanentes.

12.2. Actividad

Las actividades no son nada más que las diferentes operaciones que las entidades reciben a través de las entidades permanentes o máquinas del sistema.

Estas actividades son las que determinan el comportamiento del modelo de simulación.

Las actividades más comunes que podemos encontrar son:

- **Generación:** permite generar nuevas entidades e introducirlas dentro del modelo.
- **Destrucción:** permite destruir las entidades que han sido generadas y que ya han terminado todas las actividades que debían realizar.
- **Split:** permite crear entidades nuevas a partir de la entrada de una entidad en la actividad.
- **Join:** permite unir diferentes entidades que convergen en la actividad.
- **Demora:** demora en el tiempo de simulación la circulación de la entidad de actividad en actividad.
- **Pedir recurso:** permite solicitar un determinado recurso, para poder continuar con las siguientes tareas.
- **Liberar recurso:** permite liberar un recurso que ha sido necesario para desarrollar una serie de tareas, y que ya no es necesario.

Estas son las actividades más básicas que se pueden encontrar en un modelo de simulación.

12.3. Proceso

Un proceso no es nada más que la descripción de un conjunto de actividades que una determinada entidad debe realizar dentro del modelo.

De esta forma, toda entidad tendrá como mínimo un proceso asociado (si una entidad no tiene ningún proceso asociado, significa que no realiza ninguna actividad dentro del modelo, con lo que no tendría sentido incorporarlo).

12.4. Recurso

Un recurso necesario para realizar una actividad en el marco de un proceso.

13. Estrategias de simulación discreta

Dentro de la simulación discreta podemos encontrar diferentes estrategias para enfrentarnos al problema del modelado de un sistema.

Principalmente, las tres estrategias que encontramos son:

- 1) Interacción de procesos (*process interaction*).
- 2) Exploración de actividades (*activity scanning*).
- 3) Programación de eventos (*Event Scheduling*).

Estas diferentes estrategias presentan, cada una de ellas, ventajas e inconvenientes respecto al resto. Sin embargo, actualmente, debido a su mayor versatilidad, el paradigma del *Event Scheduling* es el más extendido. Es el que se puede implementar más fácilmente en un computador. Es uno de los que presenta mejor comportamiento desde el punto de vista computacional.

Pasamos a continuación a describir con más detalle cada uno de estas estrategias.

13.1. Programación de eventos (*Event Scheduling*)

El elemento más importante en este paradigma de simulación son los eventos, que son aquellas acciones instantáneas que pueden cambiar el estado del modelo. Por ejemplo, el inicio del procesamiento de un elemento en una máquina, y el final del procesamiento de este elemento.

El funcionamiento básico sobre el que reposa este tipo de simulación se basa en el tratamiento secuencial de los acontecimientos, que están ordenados por tiempo (y eventualmente también por prioridad) en la llamada lista de eventos.

Una vez que un evento es tratado (procesado), se elimina de la lista de eventos. En ese momento, son destruidos.

De esta forma, cada evento lleva asociado un tiempo en el que debe ser ejecutado; debido a que los intervalos temporales entre cada evento no tienen una misma amplitud, no disponemos de una evolución regular del reloj de simulación. El reloj de simulación no es nada más que un contador (de tipo real) que contiene, en cada momento de la simulación, el tiempo en el que se encuentra el modelo.

Asimismo, los eventos son generados por las acciones asociadas al tratamiento de los propios acontecimientos.

Para entender mejor el funcionamiento del *Event Scheduling*, a continuación se plantea un ejemplo basado en un sistema GG1; es decir, llegadas y salidas que siguen una distribución cualquiera, con un único servidor para ofrecer servicio a estas llegadas.

13.1.1. Ejemplo de evolución en el tiempo

En nuestro modelo, podríamos definir inicialmente una lista de tiempo que nos indicara los instantes de tiempo en los que tenemos una llegada de un determinado elemento.


Hay que tener presente que la generación de esta lista de llegadas se puede hacer inicialmente, como se plantea en este ejemplo o, más eficientemente, en el momento en el que se necesita durante el transcurso de la simulación. El método para generar el tiempo en el que tiene lugar cada una de las diferentes llegadas se basa en la generación de variables aleatorias a partir de un generador de números aleatorios en el intervalo $[0,1)$.

Supongamos que la lista de valores aleatorios que usaremos para la simulación viene dado por la siguiente tabla:

Tiempo entre llegadas		Tiempo de servicio	
a_1	35	b_1	40
a_2	12	b_2	30
a_3	29	b_3	30
a_4	47	b_4	20
a_5	12	b_5	30

Esquemáticamente, a partir del funcionamiento del algoritmo de *Event Scheduling*, obtendríamos el siguiente cronograma:

Figura 13. Cronograma para un modelo de colas con un único servidor.



A continuación, se detallan los diferentes elementos que permiten establecer correctamente el funcionamiento de un modelo de simulación basado en *Event Scheduling*.


13.1.2. Lista de eventos

La lista de eventos es la estructura que contiene los diferentes eventos que se irán tratando a lo largo del tiempo.

Es una estructura que está ordenada por tiempo; si es necesario, también puede presentar ordenaciones por prioridad, marcadas de forma explícita en cada uno de los acontecimientos, o de forma implícita por la tipología de cada evento.

La estructura que presenta se muestra en el siguiente diagrama:

Figura 14. Lista de eventos.



De esta forma, cada tupla Evento tendrá, normalmente, tres campos:

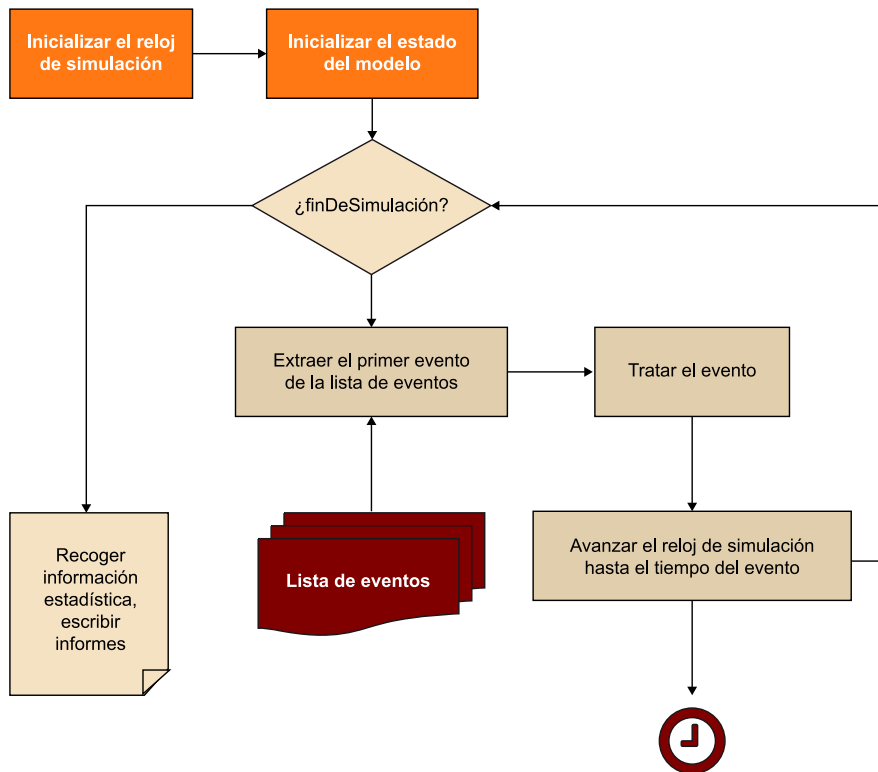
- 1) El tiempo en el que el evento se deberá ejecutar.
- 2) La prioridad. Se tendrá en cuenta únicamente en caso de que diferentes eventos tengan el mismo tiempo de ejecución.
- 3) El tipo de evento con el que estamos tratando. Es importante para asociar correctamente el procedimiento de tratamiento a cada evento.

13.1.3. Motor de simulación

El principal componente software de un modelo de simulación basado en *Event Scheduling* es el motor de simulación.

Este motor sigue siempre un esquema similar al que se presenta a continuación:

Figura 15. Motor de simulación para *Event Scheduling*.



Los bloques marcados con un color azul más intenso corresponden a lo que se llama el bucle central del motor de simulación. Este bucle es, como se puede observar, el encargado de ir procesando los diferentes eventos que estén guardados en la lista de eventos, así como de ir avanzando el reloj de simulación. Este último paso es el que hace notar que la simulación es una simulación dinámica (es decir, interviene el tiempo).

Hay que observar que, al principio de cada nueva iteración del bucle, se pregunta si ya se ha llegado al final o no de la simulación. Esta pregunta, para tener un caso general, se podría ver a partir de la evaluación de una condición booleana (llamada en el diagrama *finDeSimulación*).

Esta condición, normalmente modifica su valor a partir de tres casos diferentes:

1) A partir de un evento que indique la finalización de la simulación.

2) Por ejemplo, en el momento en el que este evento se trata, se indica en la variable booleana «finDeSimulación» que hay que acabar con la simulación.

3) A partir de un número determinado de eventos.

Indicaríamos que queremos procesar un determinado número de eventos; cuando llegamos a este número, se actualiza el valor de la condición booleana de finalización.

A partir de un tiempo final de simulación.

Determinaremos un instante de tiempo en el que la simulación debe detenerse. Este instante de tiempo normalmente tendría relación con la longitud de una repetición de un experimento de simulación. Cada vez que actualizamos el reloj de simulación, comprobamos si hemos llegado ya al tiempo de finalización; en caso de que esto sea así, entonces habrá que actualizar la variable booleana para parar el bucle.

Esta es la condición más común de terminación de una simulación.

Finalmente, la escritura de estadísticos recogerá todos aquellos valores que interesaban planteados en la formulación del problema (ver apartado anterior).

13.1.4. Tratamiento de eventos

Como se ha podido observar, el tratamiento de eventos es el único punto en el que se puede incidir para dotar al modelo de sus características y particularidades.


De esta forma, cuando se enfrenta al modelado de un sistema, es necesario, antes que nada, definir cuáles son los eventos con los que se trabajará en el modelo de simulación.

Estos eventos, como ya se ha comentado responderán, fundamentalmente, a los eventos que producirán un cambio en las variables de estado del sistema.

Una vez determinados cuáles son los diferentes eventos que podemos encontrar en el sistema, pasaremos a implementar los procedimientos adecuados para tratar cada uno de ellos. En el ejemplo que nos ocupa, un GG1, los dos tipos de eventos que podemos tener son los de llegada (llegada) y el de fin de servicio (finDeServicio).


Los algoritmos para el tratamiento y cada uno de estos dos eventos se pueden ver en los siguientes dos diagramas de flujo. Para el tratamiento del evento llegada:

Figura 16. Diagrama para el tratamiento de llegada.



Para el tratamiento del evento finDeServicio:

Figura 17. diagrama para el tratamiento del fin de servicio.



13.2. Interacción de procesos (process Interaction)

En esta estrategia, nos basamos en el punto de vista de la entidad que fluye por el proceso.

Esta estrategia se centra, de esta forma, fundamentalmente en los diferentes procesos que sufre una entidad durante su vida dentro del modelo de simulación.

Las entidades son los elementos que más importan, pues a partir de ellas se describe todo el modelo. De hecho, el analista se basa fundamentalmente en la descripción de todo lo que le puede pasar a la entidad; es decir, describe los procesos asociados a cada entidad.

Hay que ver que la popularidad de esta estrategia de simulación reside en la posibilidad de ofrecer al modelador la capacidad de describir el comportamiento de la entidad a partir de bloques de alto nivel, que permitan la construcción de los procesos. Internamente, estos bloques, gestionados por el lenguaje de simulación concreto, pueden usar una estrategia idéntica a la de la programación de eventos

Para poder construir un simulador, nótese el hecho de que poder describir el modelo de simulación a partir de los procesos asociados a sus entidades es claramente más intuitivo; por el contrario, el código que se requiere para implementar este método se complica sensiblemente.

A continuación, se describirá un ejemplo de evolución en el tiempo de un modelo de colas general (con un único servidor) visto a partir de la metodología de Iteración de procesos.

13.2.1. Ejemplo de evolución en el tiempo

El ejemplo que trataremos se corresponde aproximadamente a un proceso GG1 (siguiendo la notación Kendall para modelos de colas).


Imaginemos que tenemos inicialmente un sistema GG1, en el que únicamente contamos con un servidor; pueden llegar a partir de la distribución G entidades que tendrán un proceso asociado. Sin embargo, en nuestro caso, supondremos que un porcentaje pequeño de las entidades que entran en el sistema no requiere los servicios del servidor, sino que simplemente van a sufrir una demora en función de una probabilidad inicial, que supondremos de $1/3$.

De esta forma, podríamos entender que dentro de nuestro modelo de simulación existen dos procesos, que se pueden asignar a cada una de las entidades que entran dentro del modelo.

- El primer proceso, denotado por P 1, sería el proceso normal de un sistema GG1, en el que la entidad que llega requiere los servicios del servidor.
- El segundo proceso, denotado por P 2, sería aquel en el que las entidades no requieren del trabajo del servidor, pues simplemente sufrirán una demora.

A partir de esta pequeña descripción, se podría tener una situación como la que se muestra a continuación.

Figura 17. Cronograma para Interacción de procesos.



13.2.2. Lista de actividades

Por simplicidad, se puede considerar que tenemos dos listas de actividades: las que se deben procesar en el instante de tiempo actual; y las que se deben procesar en el futuro.


La estructura sería muy similar a la mostrada en la lista de eventos del Event Scheduling; sin embargo, ahora cada uno de los eventos presenta una fuerte relación con la entidad y con el proceso que representa.

13.2.3. Motor de simulación

El motor de simulación se basa en hacer avanzar el máximo que pueda cada una de las diferentes entidades que lleguen al sistema.

En los siguientes esquemas se puede ver una representación de un motor basado en interacción de procesos:

Figura 19



Hay que tener presente que el hecho de mover las entidades lo más posible en su lista de actividades viene siempre limitado por dos factores:

- 1) El temporal, pues solo trabajamos con las actividades en el instante actual de tiempo:
- 2) El «espacial», pues podemos encontrar diferentes actividades que requieran un mismo recurso; en este caso, tendremos que una actividad sufrirá una demora.

13.3. Exploración de actividades (*activity scanning*)

La tercera gran estrategia para construir simuladores es la exploración de actividades.

Esta estrategia orbita en torno al punto de vista del conjunto de actividades por ejecutar; su enfoque radica en identificar la naturaleza de cada una de las diferentes actividades.

La exploración de actividades usa, a diferencia de los otros dos enfoques, un incremento fijo del tiempo. Cada vez que hay un incremento en el tiempo, se explora la lista de actividades para comprobar si existe alguna que se puede desarrollar.

De esta forma, el modelador se centra en el conjunto de restricciones que existen para que cada actividad se pueda desarrollar.

El principal inconveniente de esta estrategia es precisamente que se necesite un incremento fijo en el tiempo, lo que implica que es necesario que este Δt sea lo suficientemente pequeño como para que no se produzcan de forma simultánea eventos que de otra forma aparecerían separados en el tiempo.

Muchas veces, esta necesidad conlleva un incremento considerable del coste computacional de la simulación.

Esta deficiencia en la aplicación de tal metodología de forma pura ha hecho que se hagan algunas evoluciones en ella, para poder tener incrementos variables en el tiempo, que permiten obtener un resultado mucho mejor, computacionalmente hablando.

La estrategia es la denominada de tres fases (Law y Kelton, 2000) y se mostrará a continuación en la descripción del motor de simulación.

13.3.1. Lista de actividades

Fundamentalmente, con esta metodología tenemos una lista de actividades que permite determinar en cada momento cuáles son las actividades que se pueden desarrollar.


Estas actividades estarían condicionadas a una serie de acontecimientos que marcarían la posibilidad de su ejecución.

En el caso de la estrategia de tres fases, tendríamos también una lista de eventos que irían desencadenando cambios en el estado del sistema y permitirían la ejecución de diferentes actividades.

Motor de simulación

Si nos basamos en el modelo pus tendríamos el siguiente motor de simulación:

Figura 20



El motor de simulación basado en la estrategia de tres fases es el siguiente:

- 1) Extraer de la lista de eventos futuros el evento más cercano en el tiempo, y hacer avanzar el reloj de simulación hasta este instante.
- 2) Ejecutar todos los acontecimientos extraídos de la lista de eventos.
- 3) Explorar las actividades asociadas a eventos condicionados (en este punto, se establecería un modelo básicamente puro de exploración de actividades).

14. Análisis y obtención de datos

Hay que tener presente, que previo a todo estudio de simulación hay que analizar la forma en que presentan los datos que se usarán para implementar las diferentes distribuciones que encontraremos en el modelo.

La obtención de los datos para realizar un estudio de simulación suele ser una fase laboriosa y no siempre fácil de realizar, pues la información necesaria para realizar la construcción del modelo muchas veces está distribuida entre diferentes personas.

Además, una vez que obtenemos estos datos, hay que ajustar las diferentes distribuciones empíricas que obtenemos a una distribución teórica.

Por ejemplo, podríamos tener los siguientes tiempos entre llegadas de material a una determinada planta industrial:

0,33763961 0,33763961	0,24937032 0,24937032	0,27724179 0,27724179	0,00293207 0,00293207	0,00722339 0,00722339	0,15224899 0,15224899	0,44864335 0,44864335	0,33763961 0,33763961
0,1136832 0,1136832	0,69405488 0,69405488	0,52433409 0,52433409	0,69642073 0,69642073	0,75935017 0,75935017	0,78936462 0,78936462	0,56123995 0,56123995	0,1136832 0,1136832
0,14884788 0,14884788	0,04635445 0,04635445	0,45841612 0,45841612	0,31601874 0,31601874	0,83133604 0,83133604	0,76260635 0,76260635	0,76829265 0,76829265	0,14884788 0,14884788
0,61342575 0,61342575	0,66559261 0,66559261	0,99631334 0,99631334	0,00459903 0,00459903	0,3784393 0,3784393	0,86370568 0,86370568	0,66480379 0,66480379	0,61342575 0,61342575

A partir de estos datos es importante encontrar cuál es la distribución teórica que siguen, para usarla en el simulador.

Bibliografía recomendada

Para más información referente al proceso de preparación de datos se pueden consultar estos dos artículos:

Bilalli, B.; Abelló, A.; Aluja-Banet, T. y otros (2017). «Intelligent assistance for data pre-processing». *Computer Standards & Interfaces* (vol. 57, marzo, págs. 101-109).

Gibert, K.; Sánchez-Marré, M.; Izquierdo, J. (2016). «A survey on pre-processing techniques: Relevant issues in the context of environmental data mining». *AI Communications* (vol. 29, núm. 6, pág. 627-663).

De forma simétrica al problema de captación de datos, en muchos estudios de simulación se llega a invertir mucho tiempo y dinero en hacer el modelo y el programa, pero se hace un pequeño esfuerzo para analizar correctamente la salida de la simulación. Muchos estudios de simulación finalizan con una sola ejecución y toman el resultado de la simulación para estimar las características reales del modelo, sin considerar su corrección estadística. Debe tenerse en cuenta que las entradas del modelo son variables aleatorias, tales que, al azar,

pueden tener grandes variaciones que inevitablemente afectan el resultado de la ejecución. Una implementación del modelo puede avanzar de manera importante a las características reales del modelo. Por lo tanto, hay una probabilidad razonable de que las decisiones adoptadas en el sistema sobre la base de una sola ejecución estén equivocadas.

Las razones que conducen a un mal análisis de los resultados generalmente son:

1) Muchas veces toman la simulación como un ejercicio de programación. Comienza con la construcción de un modelo, su codificación y, finalmente, el desarrollo de una sola ejecución para extraer resultados.

2) Se utilizan métodos estadísticos inadecuados. En la mayoría de las simulaciones, las salidas no son estacionarias y autocorrelacionadas. Así, las técnicas estadísticas en función de observaciones independientes e idénticamente distribuido (IID) no son aplicables directamente.

3) Otro impedimento es el coste en tiempo para recoger la cantidad necesaria de datos para aplicar técnicas estadísticas con garantías de éxito. Esto es un inconveniente relacionado con el costo de la máquina; aunque el precio del hardware se está reduciendo mucho, se tiene que considerar, dado que los tiempos de ejecución pueden ser elevados.

Analizando más específicamente la naturaleza aleatoria de las salidas de una simulación, tenemos que $X_1, X_2, \dots$ es una salida de un proceso estocástico de un escenario del simulador. Por ejemplo, X_j podría ser la duración media de una cola durante una hora. X_j son variables aleatorias que, en general, no son ni independientes ni idénticamente distribuidas. Así, como ya se mencionó anteriormente, las técnicas estadísticas no pueden aplicarse directamente.

Sea $x_{11}, x_{12}, \dots, x_{1m}$ de una realización de variables aleatorias $X_1, X_2, \dots, X_m$ resultado hacer una simulación de la longitud de m observaciones utilizando números aleatorios $u_{11}, u_{12}, \dots$, donde u_{ij} es el n^{th} número aleatorio para j -ésima. Si se ejecuta la simulación con diferentes juegos de números aleatorios, se obtendrán diversas $x_{21}, x_{22}, \dots, x_{2m}$ para las variables aleatorias $X_1, X_2, \dots, X_m$. En general, supongamos que tienes n réplicas independientemente (ejecuciones) de la simulación de longitud m , usando diferentes números aleatorios, considerando que las variables estadísticas se inicializan en el inicio de la ejecución, y cada repetición utiliza las mismas condiciones iniciales, obtenemos por resultado a partir de las observaciones:

$x_{11}, \text{el} \dots x_{119}, \dots, x_{1m}$

$x_{21}, \text{la} \dots x_{2i}, \dots, x_{m2}$

..

$x_{n1}, \dots, x_{0x}, \text{etc.},_{nm}$

Estas observaciones para un escenario dado claramente no son IID. Sin embargo, es necesario tener en cuenta que $x_{11}, x_{2i}, \dots, x_o$ son IID observaciones de X_y , para $i = 1, 2, \dots, m$. La independencia entre ejecuciones es la clave de los métodos estadísticos utilizados para el análisis de los resultados.

15. El concepto de réplica

El concepto de repetición o réplica es fundamental dentro de un experimento de simulación, y es necesario debido a la naturaleza aleatoria de las salidas en un modelo de simulación.

Si tomamos por ejemplo la secuencia $X_1, X_2, \dots$ que representa una salida del simulador, es decir, un proceso de estocástico, cada uno de ellos podría representar un valor de una variable de interés estudiado. Las variables X_y son variables aleatorias, que en general no son ni independientes ni idénticamente distribuidas. Por eso no es posible aplicar directamente las estadísticas comunes técnicas. Para solucionar este problema utiliza el concepto de espejo, o repite el experimento.

Si ahora tomamos la secuencia $x_{11}, x_{12}, x, \dots, x_{1m}$ como $X_1, X_2, \dots$ etcétera. X_m , que no es más que el resultado de hacer una primera simulación de observaciones m , utilizando una tira de números al azar determinados y conocido, por ejemplo, u_{11}, u_{12}, u donde ij es el número aleatorio del i -ésimo para correr j -ésima,

Si la simulación está a cargo de diferentes números al azar, se obtienen diferentes realizaciones de la forma $x_{k1}, x_{k2}, \dots, x_{km}$ en la misma sucesión de la variable aleatoria $X_1, X_2, \dots$ etcétera. X_m .

Cada uno de estos logros diferentes; es decir, cada una de estas repeticiones del experimento basado en la serie de números aleatoria diferente se llama una réplica.

En general, suponemos que toma K espejos independientes (ejecuciones) de la simulación de longitud m , que será independiente mientras utilizan diferentes números aleatorios; el resultado sería similar al que se muestra a continuación:

$x_{11}, \text{el} \dots x_{119}, \dots, x_{1m}$

$x_{21}, \text{la} \dots x_{2i}, \dots, x_{m2}$

.....

$x_{n1}, \text{etc. } x_{ki}, \dots, x_{km}$

Donde se puede ver una primera carrera marcada por las observaciones $x_{11}, \dots, x_{119}, \dots, x_{m1}$ de la variable de interés x .

Cada una de las diferentes observaciones de un espejo dado claramente no son IID; sin embargo, cabe señalar que cada serie de $x_{11}, x_{21}, \dots, x_{m1}$ son IID observaciones de X_1 , para $i = 1, 2, \dots, m$. Independencia entre ejecuciones fueron clave para los métodos estadísticos utilizados para el análisis de los resultados.

15.1. Intervalo de confianza

Sobre la base de los datos obtenidos de las réplicas de k de la simulación, es interesante calcular intervalos de confianza para cada una de las variables de salida de esta manera, si una variable particular se comporta como se esperaba dentro del modelo (verificación) y dentro del sistema (validación).

El objetivo es estimar el valor μ de las diferentes x_1, x_2 , etcétera. x den valores de una variable al azar dada de la ejecución de espejos independientes de K .

Por lo que puede ser x_1, x_2 , etcétera. x_n IID variables aleatorias que provienen de la misma distribución con media μ y varianza σ^2 .

La media de la muestra se calcula de la siguiente expresión: $\bar{X} = \frac{\sum_{i=1}^k x_i}{k}$ que es un estimador no sesgado de μ .

Análogamente, la varianza de la muestra se calcula a partir de la expresión:

$S^2 = \frac{\sum_{i=1}^k x_i - \bar{X}}{k-1}$ que es también un estimador no sesgado de σ^2 .

El principal problema con el que nos enfrentamos cuando usamos $\bar{X}$ como estimador de μ sin ninguna información adicional es que no existe forma de saber si $\bar{X}$ está cerca de μ o no.

Es necesario notar que, debido a que $\bar{X}$ es una variable aleatoria con varianza $\text{Var}(\bar{X}) = \frac{\sigma^2}{k}$, en un experimento $\bar{X}$ puede estar cerca de μ , mientras que en otro el valor obtenido puede estar muy alejado de μ . Por tal motivo, hay que construir un intervalo de confianza que permita establecer los niveles de certeza del dato que estamos aportando de forma empírica. La construcción de un intervalo de confianza aproximado $100(1-\alpha)$ por ciento ($0 < \alpha < 1$) viene dado por la expresión siguiente:

$$\bar{X} \pm t_{1-\alpha/2, n-1} \sqrt{\frac{S^2}{K}}$$

Donde $t_{1-\alpha/2, n-1}$ es el punto crítico superior $(1-\alpha/2)$ para la distribución t-Student con $n-1$ grados de libertad. Esto permitirá establecer que, dado un nivel de confianza α , μ estará dentro de este intervalo.

Debido a que la varianza de la muestra depende del nombre K de replices, es necesario establecer cuál es este número de réplicas necesarias. Como se verá, el procedimiento es iterativo i nos permite acercarnos, cada vez más, al nombre k adecuado.

15.2. Estimación del número «K» de réplicas necesario

A partir del cálculo de la anchura del semiintervalo de confianza h , mostrado en el apartado anterior, $h = t_{1-\alpha/2, n-1} \frac{S}{\sqrt{n}}$, es posible determinar cuál es el porcentaje que se desea que represente del valor medio de la muestra, $\bar{X}$. El cálculo del número de réplicas se calcula a partir de la expresión mostrada a continuación:

$$n^* = n \left(\frac{h}{h^*} \right)^2$$

Donde:

n = número de réplicas de la prueba piloto.

n^* = número de réplicas necesarias.

h = semiintervalo de confianza de la prueba piloto.

h^* = semiintervalo de confianza para el total de réplicas, el valor deseado.

La prueba piloto no es nada más que un conjunto inicial de réplicas del experimento que se realizan para poder comenzar a aplicar la expresión anterior.

15.3. Métodos de análisis

A continuación, se presentan un conjunto de métodos para analizar el número de réplicas necesarias en todo estudio de simulación.

15.3.1. Repeticiones independientes

Este es el método más simple e intuitivo para realizar las K réplicas necesarias en todo el estudio de simulación. A partir del mismo estado inicial del modelo, es decir, con la misma parametrización y comportamiento, varían únicamente

A partir del mismo estado inicial del modelo, es decir, con la misma parametrización y comportamiento, variamos únicamente los números aleatorios usados en cada uno de los puntos de generación de elementos aleatorios. Estos

números aleatorios diferentes, o tiras de números aleatorios diferentes, permiten probar de nuevo el sistema donde los eventos que no se controlan por parte de la experimentación, aleatoriedad, tomarán valores diferentes; por lo tanto, tendremos un resultado sensiblemente diferente para las variables analizadas.

A partir del uso de cada una de las diferentes tiras de números aleatorios, generamos una réplica de la simulación. Estos conjuntos de réplicas ofrecerán los valores necesarios para poder realizar los análisis estadísticos.

15.3.2. *Batch means* (medias de lotes)

Otra técnica es ejecutar una simulación suficientemente larga, y después de dividir esta en bloques o lotes de observaciones, trabajaremos con los valores promedios de estas observaciones. Cada una de estas observaciones las consideraremos como observaciones independientes. Hay que determinar cuál debe ser la longitud suficiente de cada uno de estos lotes de observaciones para poder garantizar la corrección del experimento. Los métodos más comunes para garantizar esta medida son:

- Regles para lotes.
- Método de las medias de lotes con estimación consistente.
- Método de las series temporales estandarizadas.
- ...

15.3.3. Métodos regenerativos

Si las variables que observamos en la simulación sufren, en cierta forma, un reinicio cíclico que permite suponer la existencia de ciclos dentro de la vida de cada variable, se puede considerar el tratamiento de cada uno de estos ciclos como si de una réplica se tratara.

Este método no es aplicable siempre, pues depende, evidentemente, de la existencia de estos ciclos dentro de la vida de las variables; aunque esto fuera así, los ciclos pueden ser muy largos, y por tanto en una simulación entera tendríamos pocas réplicas.

15.4. Técnicas de reducción de la varianza

Interesa que la variabilidad producida por el uso de generadores de números aleatorios sea mínima en el resultado de las variables respuesta. Para conseguir una variabilidad mínima, se pueden usar una serie de técnicas, denominadas de reducción de la varianza, que tienen como objetivo reducir al máximo el

«ruido» de las respuestas. Lo que interesa en definitiva es que el valor del estimador de una determinada variable respuesta, que viene representado por su intervalo de confianza,

$$(\bar{x} - k s / \sqrt{n}, \bar{x} + k s / \sqrt{n})$$

sea lo más ajustado posible. Es evidente que si aumentamos n , que es el número de muestras, el error estándar $s / \sqrt{n}$ disminuye; no obstante, las técnicas de reducción de la varianza intentan disminuir esta variabilidad sin la necesidad de aumentar el número n de la muestra.

15.4.1. Números aleatorios comunes

En caso de que se deseara evaluar dos configuraciones posibles, una buena técnica es basarse en el uso de la misma tira de números aleatorios para las dos configuraciones. Estas dos tiras idénticas representan las «condiciones idénticas» a las que ambas configuraciones están sometidas. Para realizar correctamente el método se ha de poder sincronizar las tiras de números aleatorios.

15.4.2. Variables antitéticas

Este es otro método muy sencillo, que se basa en el uso de los valores antitéticos de la tira de números aleatorios usados. En una primera ejecución, los números aleatorios usados serían $(a, b, c, \dots) \in [0, 1)$, mientras que en la segunda ejecución tendríamos sus valores antitéticos, es decir $(1-a, 1-b, 1-c, \dots) \in [0, 1)$.

De nuevo, como en el método anterior, sería necesario, para un correcto uso de la técnica, poder establecer una sincronización entre las dos tiras de números aleatorios.

15.4.3. Variables de control

La simulación permite la monitorización durante el transcurso del experimento. Esto permitiría, en cierta medida, comparar los valores que las diferentes variables respuesta van tomando a lo largo de ella con los valores observados. De esta forma, se pueden introducir modificaciones para disminuir la diferencia.

16. Diseño de experimentos en simulación

La metodología de diseño de experimentos (Law y Kelton, 1991) estudia cómo realizar comparaciones entre diferentes configuraciones del modelo, que en efecto pueden representar sistemas diferentes.

Se intenta que estas comparaciones sean lo más homogéneas posibles, con el objetivo de aumentar la posibilidad de detectar cambios y, sobre todo, identificar las variables influyentes.

De esta forma, el objetivo del experimento es estudiar el efecto sobre una variable de interés denominada respuesta, de otras variables denominadas factores o, también, variables experimentales.

Por ejemplo, en un sistema de cajeros en un gran espacio comercial, podríamos estudiar la longitud media que existe para cada una de sus cajas (variable de interés), en función de tres factores, como podrían ser el número de cajas que existen (factor), el tiempo de servicio medio de cada cajero (factor) y el número de clientes que pasan por caja (factor).

Todo factor o variable experimental puede ser cuantitativo o cualitativo. Siguiendo el ejemplo anterior, un factor cuantitativo sería el número de mostradores de facturación, mientras que el tiempo de respuesta podría ser un factor cualitativo si, por ejemplo, los valores que tenemos son bueno, malo o normal. Es necesario tener presentes tres principios para poder desarrollar correctamente un buen análisis de experimentos:

- 1) Aleatorización: se asigna al azar a todos los factores no controlados del experimento; i. e, se asignan distribuciones de probabilidad para representar el flujo de llegadas de peticiones a un servidor.
- 2) Repetición del experimento (réplicas): es una forma eficaz de reducir la variabilidad entre las repuestas.
- 3) La homogeneidad estadística de las respuestas: para comparar diferentes alternativas derivadas de los resultados, es necesario que se realicen bajo condiciones homogéneas. Para conseguir esta similitud se realizan los denominados diseños factoriales de experimentos.

Estos principios de diseño han de estar garantizados en cualquier experimento.

Un experimento de simulación garantiza su cumplimiento, dado que cada respuesta, al estar generada desde un modelo de simulación, es en sí misma ya aleatoria. Hay que notar que cada variable incorporada dentro del modelo de

simulación puede seguir una distribución de probabilidad aleatoria cuando no se controle completamente su naturaleza y pueda tratarse como un elemento determinista.


Además, se trabaja siempre sobre un conjunto de réplicas o repeticiones, para poder reducir su varianza y dotar de esta forma de validez al modelo.

Por último, el diseño factorial de un experimento garantiza la homogeneidad de los experimentos por analizar.

16.1. Diseños factoriales

La inspección clásica consiste en cambiar en cada experimento uno de los factores. Por ejemplo, si tuviéramos tres factores, el procedimiento por seguir sería fijar dos factores, al nivel (valor) de partida y varía el tercero en todos sus niveles hasta determinar un óptimo. Una vez escogido el óptimo para un factor, este se fijaría y se repetiría el proceso para los otros factores.

Este puede parecer un buen procedimiento, pero sus garantías de éxito decaen rápidamente cuando se trata de un sistema donde hay una interacción entre sus factores. En el caso de dos factores, el proceso sería el siguiente:




Cada uno de los efectos se calcula de la siguiente forma:

Efecto de A: $A_1B_0 - A_0B_0$.

Efecto de B: $A_0B_1 - A_0B_0$

El diseño factorial consiste en cruzar todos los niveles de cada factor. De esta forma se contemplan las interacciones entre factores:



Cada uno de los efectos individuales en este caso se calculan de la siguiente forma:

Efecto de A:

$$\frac{A_1B_0 - A_1B_1}{2} - \frac{A_0B_0 - A_0B_1}{2}$$

Efecto de B:

$$\frac{A_1B_1 - A_0B_1}{2} - \frac{A_0B_0 - A_1B_0}{2}$$

Así se puede decir que los diseños factoriales permiten estimar los efectos de los diferentes factores de una forma más precisa.

Los diseños factoriales generales consisten en controlar k factores y se consideran los niveles (valores) diferentes para el factor i -ésimo. El diseño requerirá $l_1 \cdot l_2 \cdot \dots \cdot l_k$ experimentos. El diseño factorial más sencillo es 2^k donde $\forall i = 1, \dots, k$. Aunque sea un diseño sencillo, tiene una serie de ventajas que hace que sea uno de los más usados.

- Determinación de la tendencia con economía de los experimentos (suavidad).
- Posibilidad de aumentar a diseños compuestos (exploración local localizada).
- Puede servir de base para diseños factoriales fraccionados (permitiendo la visión rápida de muchos factores).
- Tiene una interpretación y un análisis sencillo.

16.2. Diseños factoriales 2^k

Como se ha explicado, el diseño factorial 2^k está basado en que para cada factor se analicen únicamente dos niveles posibles; es decir, dos valores únicos.

Terminológicamente, se asigna un signo negativo «-» a uno de los niveles (normalmente el que representa el caso base), y un signo positivo «+» al otro. Esta asociación responde usualmente al hecho de que el nivel «-» representa la alternativa actual, es decir, sin modificar el sistema; mientras que el signo positivo «+» representa la alternativa que se quiere analizar. Si esta notación semántica no es posible (porque por ejemplo el sistema no existe y lo que se plantea es simplemente un análisis de diferentes alternativas), el signo puede representar simplemente el valor más grande o el más pequeño.

La matriz para un diseño 2^k tiene el siguiente aspecto:

Experi- mento	Factor 1	Factor 2		Factor k	Res- puesta
1	-	-		-	R1
2	+	-		-	R2
3	-	-		-	R3
4	+	-		-	R4
5	-	+		-	R5
6	+	+		-	R6
2^k	+	+		+	$R2^k$

16.2.1. Cálculo de los efectos

Para ver como se calculan los efectos en un diseño 2^3 partimos de una tabla como la siguiente:

Experimento	A	B	C	Respuesta
1	-	-	-	60
2	+	-	-	72
3	-	+	-	54
4	+	+	-	68
5	-	-	+	52
6	+	-	+	83
7	-	+	+	45
8	+	+	+	80

El efecto principal de un factor es la media de todos los efectos individuales sobre las condiciones de los otros factores. El efecto individual de un factor es el cambio en la respuesta, al variar el nivel del factor de signo negativo a positivo. El efecto principal de cada factor se calcula:

$$\text{Efecto Principal} = \bar{y}_+ - \bar{y}_-$$

Donde $\bar{y}_+$ es la respuesta media para el nivel alto del factor y $\bar{y}_-$ es la respuesta media para el nivel bajo. Así en el ejemplo:

$$A = \frac{72+68+83+80}{4} - \frac{60+54+52+45}{4} = 23$$

$$B = \frac{54+68+45+80}{4} - \frac{60+72+52+83}{4} = -5$$

$$C = \frac{52+83+45+80}{4} - \frac{60+72+54+68}{4} = 1.5$$

La interacción de dos factores se define como la mitad de la diferencia entre el efecto medio del factor 1 fijado el factor 2 a «+», y el efecto medio del factor fijado el factor 2 a «-». Como se puede observar la interacción es conmutativa.

Así, la interacción AC es:

$$AC = \frac{y_1+y_3+y_6+y_8}{4} - \frac{y_2+y_4+y_5+y_7}{4} = 10$$

donde y_i es la respuesta i-ésima.

La interacción de tres factores se define como la mitad de la diferencia entre la interacción de los factores 1 y 2 fijado el factor 3 a «+» y la interacción de los factores 1 y 2 fijado el factor a «-». En este caso, la definición es también conmutativa.


$$ABC = \frac{y_{21}+y_3+y_5+y_8}{4} - \frac{y_1+y_4+y_6+y_7}{4} = 0.5$$

Como podemos observar, esta forma de calcular los efectos es bastante laboriosa. Para simplificar este proceso vamos a introducir un algoritmo que permite calcular los efectos de una forma más rápida y fácil de implementar.

16.3. Algoritmo de Yates

El algoritmo de Yates sistematiza el cálculo de los efectos principales y las interacciones a diferentes niveles para un diseño experimental 2^k .

A partir de la siguiente figura se puede observar el funcionamiento del algoritmo de Yates de forma esquemática.



La explicación del algoritmo es la siguiente:

- 1) Colocar la respuesta en la columna «Resp», siguiendo el orden estándar de la matriz del diseño experimental seguido.
- 2) Añadir tantas columnas auxiliares como factores de diseño existan. Los valores de las columnas se completan siguiendo el esquema mostrado en la figura anterior.
- 3) Crear una nueva columna dividiendo el primer valor de la última columna auxiliar por un divisor igual al número de factores. Para el resto de los valores, el divisor es igual a la mitad del número de factores usados.
- 4) En la última columna, el primer valor corresponde al promedio de las respuestas, el resto corresponde a los efectos. La correspondencia entre los valores y efectos se realiza a través de la ubicación de «+» en las filas correspondientes a la matriz de diseño. Si un valor tiene solo una «+» en la columna del factor B, será responsable por el efecto principal de B. Si los tienes en las columnas correspondientes a los efectos de A y C, será responsable de la interacción de AC, etcétera.

En el ejemplo anterior el resultado sería:

Exp.	A	B	C	Resp	(1)	(2)	(3)	div.	efecto	Id
1	-	-	-	60	132	254	514	8	64.25	Media

Exp.	A	B	C	Resp	(1)	(2)	(3)	div.	efecto	Id
2	+	-	-	72	122	260	92	4	23.0	A
3	-	+	-	54	135	26	-20	4	-5.0	B
4	+	+	-	68	125	66	6	4	1.5	AB
5	-	-	+	52	12	-10	6	4	1.5	C
6	+	-	+	83	14	-10	40	4	10.0	AC
7	-	+	+	45	31	2	0	4	0.0	BC
8	+	+	+	80	35	4	2	4	0.5	ABC

16.4. Determinación de los efectos significativos

Dados g conjuntos de condiciones experimentales, se observan n_i repeticiones genuinas de la condición i . Entonces s_i^2 estima σ^2 con $\nu_i = n_i - 1$ grados de libertad. La estimación conjunta de σ^2 es:

$$s^2 = \frac{\sum_{i=1}^g \nu_i s_i^2}{\sum_{i=1}^g \nu_i}$$

con $\nu = \sum_{i=1}^g \nu_i$ grados de libertad.

En un diseño 2^k con un total de N experimentos

$$\sigma_{\text{efecto}}^2 = \frac{4}{N} \sigma^2$$

Un efecto es significativo con un nivel de confianza α si en valor absoluto supera claramente a:

$$\sigma_{\text{efecto}} t_{\alpha/2, \nu}$$

En el ejemplo:

Resp. media	A	B	C	Resp 1	Resp 2	s_i^2
60	-	-	-	59	61	2
72	+	-	-	74	70	8
54	-	+	-	50	58	32
68	+	+	-	69	67	2
52	-	-	+	50	54	8

Resp. media	A	B	C	Resp 1	Resp 2	s_i^2
83	+	-	+	81	85	8
45	-	+	+	46	44	2
80	+	+	+	79	81	2
					Total	64

$$s^2 = \frac{64}{8} = 8$$

$$\sigma_{efecte}^2 \approx \frac{8}{4} = 2$$

$$\sigma_{efecte} \approx \sqrt{2} = 1.4$$

Será significativo a un nivel de confianza del 95 % un efecto $> 1.4t_{0.025, 8} = 3.2284$ en valor absoluto. De esta forma los efectos significativos serán:

$$A = 23.0$$

$$B = -5.0$$

$$AC = 10.0$$

17. Análisis de resultados en simulación

17.1. Comparación de dos configuraciones del sistema

Muchos estudios de simulación nacen de la necesidad de comprobar cómo afectará el rendimiento del sistema si se lleva a cabo ciertos cambios en este. Así nos encontramos frente a la encrucijada de decidir entre dos configuraciones alternativas del sistema.

A continuación, vamos a explicar los métodos para realizar las comparaciones más comunes entre diferentes alternativas en el contexto en que nos movemos.

17.1.1. Comparación de dos configuraciones con igualdad de varianzas

Tenemos dos configuraciones del modelo en que representamos dos sistemas A y B. Se parte de una hipótesis que asume que los dos sistemas se comportan de la misma manera. Esta hipótesis se llama la hipótesis nula, H_0 . Se supone que, en el caso de no cumplir con esta hipótesis, las mediciones de los resultados del modelo tendrán un valor mayor que la medida del rendimiento de A para el modelo B. Esta hipótesis, que es la que se considerará si no se cumple la hipótesis nula, se llama hipótesis alternativa, H_1 . Como se verá más adelante, partiendo de la hipótesis nula podemos proponer diferentes hipótesis alternativas. En este caso, el enfoque que se realiza es de la forma:

$$H_0: \mu_A = \mu_B$$

$$H_1: \mu_A = \mu_B$$

Supongamos que las diferentes réplicas independientes dan los siguientes resultados:

Réplica	Medida del rendimiento para A	Medida del rendimiento para B
1	24.3	24.4
2	25.6	21.5
3	26.7	25.1
4	22.7	22.8
5	24.8	25.2
6	23.8	23.5

Réplica	Medida del rendimiento para A	Medida del rendimiento para B
7	25.9	22.2
8	26.4	23.5
9	25.8	23.3
10	25.4	24.7

Donde la media de la muestra es 25.14 y 23.62, para los modelos A y B respectivamente. La desviación estándar es 1.242 y 1.237, para los modelos A y B respectivamente.

Las medias de los valores obtenidos debido a que se consiguen como combinación lineal de variables aleatorias que provienen de la misma población, por el teorema central del límite se distribuyen de la forma:

$$\bar{y}_A \approx N(\mu_A, \frac{\sigma_A}{\sqrt{n_A}})$$

$$\bar{y}_B \approx N(\mu_B, \frac{\sigma_B}{\sqrt{n_B}})$$

Por tanto,

$$\bar{y}_A - \bar{y}_B \approx N(\mu_A - \mu_B, \sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}})$$

Y así,

$$\frac{(\bar{y}_A - \bar{y}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} \approx N(0, 1)$$

Pero no conocemos σ_A^2 ni σ_B^2 , sino que se estiman a partir de las respectivas varianzas muestrales: $s_A^2 = 1.54$, $s_B^2 = 1.53$. Dado que estos dos valores son similares, se puede suponer que la varianza para los dos modelos es la misma. Hay casos en los que las varianzas muestrales presentan una diferencia significativa, antes de dar por válida esta suposición se tiene que realizar un test de igualdad de varianzas, usando la distribución F de Snedecor, tal como se verá más adelante.

En nuestro caso, calcularemos un estimador de varianza único, s , que será la media de las dos varianzas muestrales ponderadas según los grados de libertad de cada muestra. En este caso, al tener las dos configuraciones del modelo el mismo número de réplicas consiste simplemente en hacer la media aritmética. Con este estimador único se puede escribir:

$$\frac{(\bar{y}_A - \bar{y}_B) - (\mu_A - \mu_B)}{s\sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} \approx t_n$$

Aquí $n = n_A + n_B - 2$ y por tanto t_n es una distribución t-Student con $n_A + n_B - 2$ grados de libertad.

Si se cumple la hipótesis nula, $\mu_A = \mu_B$, se ha de usar:

$$\frac{\bar{y}_A - \bar{y}_B}{s\sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} \approx t_n$$

Por tanto, a un nivel de confianza α se puede rechazar la hipótesis nula si:

$$\frac{\bar{y}_A - \bar{y}_B}{s\sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} > t_{1-\alpha, n}$$

En nuestro ejemplo, a un nivel de confianza del 95 %:

$$\frac{25.14 - 23.62}{1.24\sqrt{\frac{1}{10} + \frac{1}{10}}} = 2.74 > t_{0.05, 18} = 1.734$$

Por tanto, la hipótesis nula se puede rechazar. Se puede decir que la diferencia entre las medias muestrales es estadísticamente significativa y aceptaremos la hipótesis alternativa.

Este esquema de razonamiento se denomina contraste de hipótesis, ya que lo que se hace es suponer que se cumplen una determinada hipótesis y comprobar si los datos obtenidos a partir de las ejecuciones son coherentes con esta.

Normalmente, la hipótesis nula es del tipo que se ha planteado en el caso anterior, es decir:

$$H_0: \mu_A = \mu_B$$

La hipótesis alternativa puede ser de la forma:

$$H_1: \mu_A > \mu_B$$

$$H_1: \mu_A < \mu_B$$

$$H_1: \mu_A \neq \mu_B$$

Los dos primeros planteamientos son esencialmente idénticos (si no son iguales, una media es superior a la otra). El tercero, no obstante, refleja una mayor desinformación respecto al sistema estudiado, que se traduce indicando que

una media es simplemente diferente a la otra. En la siguiente tabla se indica el enfoque que se da en el análisis de datos en función del resultado obtenido y cuál es la hipótesis alternativa planteada.

Resultado obtenido	Planteamiento del contraste		
	$H_0: \mu_A = \mu_B$ $H_1: \mu_A < \mu_B$	$H_0: \mu_A = \mu_B$ $H_1: \mu_A > \mu_B$	$H_0: \mu_A = \mu_B$ $H_1: \mu_A \neq \mu_B$
$\bar{y}_A < \bar{y}_B$	Resultado esperado. Se trata de analizar si la diferencia obtenida es o no estadísticamente significativa.	No hace falta que realicemos ningún cálculo. Con el resultado obtenido es obvio que no podemos rechazar H_0 .	Se trata de probar si la diferencia es estadísticamente significativa o no.
$\bar{y}_A > \bar{y}_B$	No hace falta que realicemos ningún cálculo. Con el resultado obtenido es obvio que no podemos rechazar H_0 .	Resultado esperado. Se trata de analizar si la diferencia obtenida es o no estadísticamente significativa.	Se trata de probar si la diferencia es estadísticamente significativa o no.
$\bar{y}_A = \bar{y}_B$	En este caso, no podemos rechazar la hipótesis nula.		

Hay que remarcar que con la hipótesis alternativa del tipo $\mu_A \neq \mu_B$ se han de esperar diferencias de medias tanto positivas como negativas. De hecho, en este caso, dada una diferencia, se considera igualmente probable una diferencia en sentido contrario; por tanto, para un nivel de confianza α se tendrá que comparar el resultado obtenido con $t_{n,1-\alpha/2}$ en vez de $t_{n,1-\alpha}$.

17.1.2. Comparación de dos configuraciones con varianzas diferentes

Una de las hipótesis que se aplicaba para usar la técnica de comparación de medias era suponer la igualdad de varianzas. Si no se puede asumir esta hipótesis, se puede obtener una buena aproximación al nivel de significación a partir del estadístico:

$$t' = \frac{(\bar{y}_A - \bar{y}_B) - (\mu_A - \mu_B)}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}}$$

Si $n_A = n_B = n$, el nivel de significación se determina usando como distribución de referencia una t-Student con $n-1$ grados de libertad.

Si $n_A \neq n_B$, con el valor calculado de t' encuentran los niveles de significación p_A y p_B en las distribuciones de t-Student n_A-1 y n_B-1 grados de libertad, respectivamente.

En este caso, el nivel de significación de la prueba es:

$$p = \frac{\omega_A p_A + \omega_B p_B}{\omega_A + \omega_B}$$

con:

$$\omega_A = \frac{S_A^2}{n_A}$$

$$\omega_B = \frac{S_B^2}{n_B}$$

17.1.3. Test de igualdad de variancias

El test de igualdad de variancias es, como en el caso de comparación de dos configuraciones del sistema, un contraste de hipótesis. En este caso, las hipótesis son:

$$H_0: \sigma_A^2 = \sigma_B^2$$

$$H_1: \sigma_A^2 \neq \sigma_B^2$$

La distribución de referencia es:

$$\frac{S_A^2}{S_B^2} \approx F_{n,m}$$

donde

$$n = n_A - 1$$

$$m = n_B - 1.$$

Por tanto, el test para determinar si la diferencia es estadísticamente significativa con un nivel de confianza de α es:

$$\frac{S_A^2}{S_B^2} > F_{1-\alpha,n,m}$$

donde

$$n = n_A - 1$$

$$m = n_B - 1.$$

Ejemplo 1

Se tienen dos muestras provenientes de dos ejecuciones del simulador con igualdad de réplicas $n = 10$, y se obtiene $SA^2 = 1.54$ y $SB^2 = 2.18$. ¿Se puede considerar que las variancias son iguales?

$$\frac{S_B^2}{S_A^2} = \frac{2.18}{1.54} = 1.42 < F_{0.05,9,9} = 3.18$$

Por tanto, nada hace suponer que se pueda rechazar la hipótesis nula de igualdad de varianzas.

Ejemplo 2

Se tienen dos muestras provenientes de dos ejecuciones del simulador con igualdad de réplicas $n = 10$, y se obtiene $SA^2 = 1.54$ y $SB^2 = 16.3$. ¿Se puede considerar que las variancias son iguales?

$$\frac{S_B^2}{S_A^2} = \frac{16.3}{1.54} = 10.58 > F_{0.05,9,9} = 3.18$$

Por tanto, en este caso se puede rechazar la hipótesis nula y considerar que la diferencia entre las varianzas es estadísticamente significativa.

18. Verificación/Validación y acreditación de un modelo de simulación

Llegados a este punto, ya conocemos las técnicas básicas para poder determinar si un modelo de simulación es válido para un conjunto de propósitos concretos y definidos previamente.

Debido a la naturaleza de los estudios de simulación y a las implicaciones que estos acostumbran a tener en los sistemas reales, hay que definir y estructurar una metodología que permita determinar si un modelo es válido no en función de unos parámetros apropiados de calidad y de fiabilidad.

Terminológicamente, para referirnos a la verificación, validación y a la acreditación lo haremos a través de sus siglas VV&A.

La verificación corresponde a la comprobación de que realmente el modelo implementado, es decir, el algoritmo, se comporta correctamente. En este punto, las técnicas de verificación computacional son comunes a la ingeniería de software y son las técnicas que se tendrían que aplicar.

La validación representa la comprobación de que el modelo de simulación se ajusta realmente al sistema que se pretende modelar.

Finalmente, la acreditación representaría la aceptación por parte del equipo directivo del sistema de que los datos que el simulador proporciona son correctos. Es decir, la aceptación oficial de que el modelo de simulación da respuesta al propósito para el que ha sido construido.

Lecturas recomendadas

Algunas referencias que se pueden revisar para profundizar más en esta parte son:

Paraskevas, A.; Katsogridakis, I.; Law, R.; y otros (2011). «Search Engine Marketing: Transforming Search Engines into Hotel Distribution Channels». *Cornell Hospitality Quarterly* (vol. 52, págs. 200-208).

Robinson, S. (1999). «Simulation verification, validation and confidence: a tutorial». *Simulation: Transactions of The Society for Modeling and Simulation International* (vol. 16, núm. 2, págs. 63-69).

Robinson, S.; Brooks, R. J. (2010). «Independent verification and validation of an industrial simulation model». *Simulation: Transactions of The Society for Modeling and Simulation International* (vol. 86, núm. 7, págs. 405-416).

Sargent, R. G. (2009). «Verification and validation of simulation models». En: *Actas de la 2009 Winter Simulation Conference (WSC)* (vol. 37, núm. 2, págs. 66-66).

Sargent, R. G. (2013). «Verification and validation of simulation models». *Journal of Simulation* (vol. 7, núm. 1, págs. 12-24, febrero).

Sargent, R. G. (2015). «An interval statistical procedure for use in validation of simulation models». *Journal of Simulation* (vol. 9, núm. 3, págs. 232-237, agosto).

18.1. Verificación

Hay que verificar que el modelo implementado en la computadora se comporta adecuadamente. **Es decir, construir el modelo correctamente.**

Se pueden aplicar técnicas comunes de la ingeniería de software. Dos técnicas adecuadas en el presente contexto son:

1) **Pruebas estáticas:** se analizan las propiedades estructurales del código para evaluar si es correcto.

2) **Pruebas dinámicas:** el programa se ejecuta bajo diferentes condiciones iniciales para comprobar si realmente funciona como es de esperar. Los resultados que se obtienen se usan para determinar si la implementación es correcta o no.

18.2. Validación

La validación del modelo de simulación intenta responder a la pregunta: ¿es el modelo que hemos construido una representación adecuada del sistema real? **Es decir, construir el modelo correcto.**

El proceso para realizar esta validación se puede resumir en los siguientes pasos:

1) Validez de los datos: es evidente que, aunque el simulador sea totalmente válido, si los datos que se le proporcionan no son correctos, los resultados que se obtendrán no serán buenos. Por tal razón, en primer lugar es necesario asegurarse de que los datos con los que trabajamos son válidos.

2) Validación del modelo conceptual: en cualquier modelo de simulación, muchas veces debido a las limitaciones del lenguaje de programación (o sistema de simulación) que se utilizará para llevar a cabo la implementación será necesario tomar una serie de hipótesis simplificadoras. En cualquier caso, es necesario que todas estas hipótesis y suposiciones sean apropiadas y correctas, y también se debe determinar si la estructura lógica que representa el modelo es también aceptable.

3) Validación operacional: en este paso miraremos si las salidas que proporciona el modelo tienen la exactitud requerida de acuerdo con el problema que se quiere resolver. Entre otras técnicas se pueden usar:

a) Comparación gráfica de los datos del modelo con los datos del sistema real.

b) Intervalo de confianza para medias, variancias o distribuciones para las diferentes salidas del modelo.

c) Series temporales para las salidas del modelo que permitan comprobar si realmente se adecuan a lo esperado.

En este punto, las técnicas de representación (visualización 2D, 3D, realidad virtual o aumentada) pueden ser extremadamente útiles para comprobar de forma visual si el modelo es correcto o no.

Asimismo, podemos clasificar las técnicas que existen para realizar la validación en:

- Técnicas informales
- Técnicas estáticas
- Técnicas dinámicas
- Técnicas formales

18.2.1. Técnicas informales

Todo sistema contiene una lógica de operación que es conocida por los expertos. Estas son las personas que conocen el funcionamiento del sistema y son las más adecuadas para determinar si el modelo se ajusta o no se cree que es apropiado. Es necesario preservar la independencia del grupo de expertos con el fin de garantizar su objetividad.

De esta manera, por ejemplo, si el modelo de simulación representa a un aeropuerto, sería necesario incorporar dentro del equipo de simulación a un grupo de expertos en sistemas aeroportuarios, independientes del equipo de ingenieros que controla el modelo del aeropuerto, y también independiente del grupo responsable del desarrollo de la simulación y del sistema.

18.2.2. Técnicas estáticas

Fundamentalmente intentan determinar si la base sobre la que reposa la simulación es correcta. Se basan en evaluar el diseño estático del modelo y el código usado para su implementación usando este conjunto de métodos hay que tener especial atención en dos aspectos:

1) La construcción formal del modelo de simulación, a partir de una metodología adecuada que permita establecer un buen canal de comunicación entre todos los miembros del equipo de simulación y los expertos del sistema.

2) Establecer el método para, a partir del formalismo, implementar en el ordenador el modelo de simulación. Existen sistemas para realizar este paso de forma automática, garantizando este punto, por ejemplo usando el lenguaje SDL tenemos SDLPS (Fonseca, 2010) o PragmaDEV.

18.2.3. Técnicas dinámicas

Ahora no evaluaremos el modelo usando parámetros estáticos, es decir, el diseño y el código, sino que veremos y analizaremos los resultados que el simulador proporciona.

De esta forma, a partir de los datos podremos usar las técnicas estadísticas presentadas previamente para evaluar si de verdad los datos que el simulador proporciona se adecuan a la realidad o no.

18.2.4. Técnicas formales

Existe la posibilidad de, por ejemplo, a partir del cálculo de predicados, garantizar completamente la corrección del modelo. No obstante, estas técnicas acostumbran a ser laboriosas y a complicar en exceso la comprensión del modelo. Además resultan difíciles de aplicar en modelos complejos.

18.3. Acreditación

La acreditación tiene que estar dirigida por un tercer equipo, diferente del grupo contratante de la simulación y del equipo encargado de desarrollar la simulación (Robinson y Brooks, 2010).

Un conjunto de directivas bien establecidas por el Ministerio de Defensa de Estados Unidos se pueden encontrar en DoD Directive 5000.59.

Bibliografía

Banks, J. (ed.) (1998). *Handbook of Simulation Principles, Methodology, Advances, Applications, and Practice*. Nueva York: John Wiley & Sons.

Bilalli, B.; Abelló, A.; Aluja-Banet, T. y otros (2017). «Intelligent assistance for data pre-processing». *Computer Standards & Interfaces* (vol. 57, marzo, págs. 101-109).

Fonseca i Casas, P. (2009). *Simulació discreta per mitjà de la interacció de processos*. Barcelona: Edicions UPC.

Fonseca i Casas, P. (2010). «Using specification and description language to define and implement discrete simulation models». En: *Actas de la 2010 Summer Computer Simulation Conference, SCSC '10* (núm. 1, págs. 419-426).

Fonseca i Casas, P. (2011). «Simulation hypotheses A proposed taxonomy for the hypotheses used in a simulation model». En: *SIMUL 2011*. Ponencia. Barcelona, 23-29 de octubre de 2011.

Fonseca i Casas, P. (2014). *Formal languages for computer simulation: Transdisciplinary models and applications*. Hershey, PA: IGI Global. DOI:10.4018/978-1-4666-4369-7

Fonseca i Casas, P.; Casanovas, J.; Ferran, X. (2014). «Passenger flow simulation in a hub airport: An application to the Barcelona International Airport». *Simulation Modelling Practice and Theory* (vol. 44, págs. 78-94, mayo).

Fonseca i Casas, P.; Pi Palomés, X.; Casanovas Garcia, J. y otros (2013). «Definition of virtual reality simulation models using specification and description language diagrams». En: *SDL 2013: Model driven dependability engineering* (págs. 258-274). Berlín / Heidelberg: Springer-Verlag.

Gibert, K.; Sànchez-Marrè, M.; Izquierdo, J. (2016). «A survey on pre-processing techniques: Relevant issues in the context of environmental data mining». *AI Communications* (vol. 29, núm. 6, págs. 627-663).

Kelton, W. D.; Sadowski, R. P.; Sturrock, D. T. (2010). *Simulation with Arena*. Nueva York: McGraw-Hill.

Law, A. M.; Kelton, W. D. (1991). *Simulation modeling and analysis* (2.^a ed.). Nueva York: McGraw-Hill.

Law, A. M.; Kelton, W. D. (2000). *Simulation modeling and analysis* (3.^a ed.). Nueva York: McGraw-Hill.

Paraskevas, A.; Katsogridakis, I.; Law, R. y otros (2011). «Search Engine Marketing: Transforming Search Engines into Hotel Distribution Channels». *Cornell Hospitality Quarterly* (vol. 52, págs. 200-208)

PragmaDev Studio [online]. [Fecha de consulta: 9 de enero de 2016]. PragmaDev SARL, 2016. <http://www.pragmadev.com/product/index.html>

Robinson. S. (1999). «Simulation verification, validation and confidence: a tutorial». *Simulation: Transactions of The Society for Modeling and Simulation International* (vol. 16, núm. 2, págs. 63-69).

Robinson, S. (2003). *Simulation: The Practice of Model Development and Use*. Nueva York: John Wiley & Sons.

Robinson, S.; Brooks, R. J. (2010). «Independent verification and validation of an industrial simulation model». *Simulation: Transactions of The Society for Modeling and Simulation International* (vol. 86, núm. 7, págs. 405-416).

Sargent, R. G. (2009). «Verification and validation of simulation models». En: *Actas de la 2009 Winter Simulation Conference (WSC)* (vol. 37, núm. 2, págs. 66-66).

Sargent, R. G. (2013). «Verification and validation of simulation models». *Journal of Simulation* (vol. 7, núm. 1, págs. 12-24, febrero).

Sargent, R. G. (2015). «An interval statistical procedure for use in validation of simulation models». *Journal of Simulation* (vol. 9, núm. 3, págs. 232-237, agosto).

Wainer, G. A.; Mosterman, P. J. (2009). *Discrete-Event Modeling and Simulation: Theory and Applications*. Boca Raton, FL: CRC Press.